

# Mathematical Forecasting Methods

## Лекция 3

МФТИ

Осень, 2024

# Краткое повторение

- ▶ **Временной ряд** — это совокупность значения параметра  $\{x_1, x_2, \dots, x_T\} = \{x_t\}_{t=1}^T$ , изменяющегося во времени, через равные промежутки времени.
- ▶ **Также рассматриваем как:** совокупность случайных величин (*дискретный случайный или стохастический процесс*), где для каждого  $t$  значение рассматривается как случайная величина.
- ▶ **Задача прогнозирования:** найти функции  $f_{T,d}$ :


$$x_{T+d} \approx f_{T,d}(x_1, \dots, x_T; w) =: \hat{x}_{T+d},$$

где  $f_{T,d}$  — модель временного ряда,  $d = 1, \dots, D$  — горизонт прогнозирования.

## Краткое повторение

**Определение.** Временной ряд  $\{x_i\}_{i=1}^T$  называется слабо стационарным (или стационарным в широком смысле), если

- ▶  $E[x_t] = \text{const}$  (т.е. временной ряд не имеет *тренда*),
- ▶  $\text{Cov}(x_t, x_{t+k}) = E[(x_t - Ex_t)(x_{t+k} - Ex_{t+k})] = \gamma(k)$  (ковариация зависит только от разницы во времени).



Белый шум

## Краткое повторение

Модель **SARIMAX**( $p, q, d; P, Q, D$ ) приводит временной ряд к стационарному виду и прогнозирует с наперед заданной точностью (по Теореме Вольда).

$$\begin{aligned} x_t = & \underbrace{\mu + \phi_1 x_{t-1} + \phi_2 x_{t-2} + \dots}_{p \text{ слагаемых AR}} + \underbrace{u_t + \theta_1 u_{t-1} + \theta_2 u_{t-2} + \dots}_{q \text{ слагаемых MA}} \\ & + \underbrace{\alpha_1 x_{t-S} + \alpha_2 x_{t-2S} + \dots}_{P \text{ сезонных слагаемых AR}} + \underbrace{\eta_1 u_{t-S} + \eta_2 u_{t-2S} + \dots}_{Q \text{ сезонных слагаемых MA}} \\ & + \underbrace{\beta_1 z_1 + \beta_2 z_2 + \beta_3 z_3 + \dots}_{\text{внешние переменные, не зависящие от } x_t}, \end{aligned}$$

где  $\phi, \theta, \alpha, \eta, \beta$  — настраиваемые параметры модели,  
 $x_t$  — значения временного ряда (продифференцированные  $d$  и  $D$  сезонных раз),  
 $u_t$  — значения шумов,  
 $z_i$  — внешние (экзогенные) переменные.

## Подбор параметров модели

- ▶ Если все гиперпараметры модели  $p, q, d; P, Q, D$  подобраны, то коэффициенты авторегрессии подбираются методом МНК;
- ▶ Для выбора  $\theta$  шумовая компонента предварительно оценивается на остатках «простой» авторегрессии;
- ▶ Если шум гауссовский, то МНК дает оценки максимального правдоподобия.

**Вопрос:** как подбирать приближение для  $p, q, d; P, Q, D$ ?

# Информационные критерии





**Критерий Акаике (Akaike's information criterion, AIC)** — содержит функцию штрафа, линейно зависящую от числа параметров:

$$AIC = \left( \sum_{t=1}^T (x_t - \hat{x}_t)^2 \right) + 2(p + q + P + Q + 1)$$

**Байесовский информационный критерий (Bayesian information criterion, BIC):**





$$BIC = \left( \sum_{t=1}^T (x_t - \hat{x}_t)^2 \right) + (p + q + P + Q + 1)(\ln T - 2)$$

# Начальное приближение гиперпараметров



- ▶  $Q * S$  — номер последнего **сезонного** лага, при котором автокорреляция статистически значима;
- ▶  $q$  — номер последнего **несезонного** лага, при котором автокорреляция статистически значима, меньше сезонного значения;


# Начальное приближение гиперпараметров



- ▶  $P * S$  — номер последнего **сезонного** лага, при котором **частичная автокорреляция** статистически значима;
- ▶  $p$  — номер последнего **несезонного** лага, при котором **частичная автокорреляция** статистически значима, меньше сезонного значения;



# Проблема непостоянной дисперсии



Дневные изменения фондового индекса биржи

# ARCH и GARCH модели

В традиционных эконометрических моделях дисперсия шума считается постоянной (гомоскедастичность).

Если временные ряды демонстрируют периоды необычно большой волатильности\*, за которыми следуют периоды относительного спокойствия, предположение о постоянной дисперсии не выполняется. Для учета такого эффекта используются модели:

- ▶ ARCH (autoregressive conditional heteroskedastic model),
- ▶ GARCH (generalized autoregressive conditional heteroskedastic model).

\* Термин **волатильность** в финансовой аналитике — это отклонение доходности (непредсказуемая часть цен на активы).

## Изменяющаяся волатильность

- ▶ Модель AR(1):  $x_t = \mu + \phi_1 x_{t-1} + u_t = \mu_t + u_t$
- ▶ Здесь  $\mu_t$  и  $u_t$  — ожидаемая часть с учетом истории и случайная часть соответственно.
- ▶ Если ранее полагалось, что  $u_t \sim WN(0, 1)$ , то теперь возмущения будут моделироваться с меняющейся во времени дисперсией  $\sigma_t^2$ :

$$u_t = z_t \sqrt{\sigma_t^2},$$

где  $z_t \sim WN(0, 1)$

- ▶  $\sigma_t^2$  является функцией предыдущих значений ошибки  $u_{t-1}, u_{t-2}, \dots$

# Историческая волатильность

Скользящее среднее.



$$\sigma_t^2 = \sum_{i=1}^N \frac{r_{t-i}^2}{N},$$

где  $r_t$  — ошибка прошлых прогнозов,

- ▶ учитывает изменения с задержкой,
- ▶ сложности с большим горизонтом прогнозирования.

Экспоненциальное сглаживание



$$\sigma_t^2 = \lambda r_{t-1}^2 + (1 - \lambda) r_{t-2}^2,$$





- ▶ новый гиперпараметр  $\lambda$ ,
- ▶ нестабильный переход от «большой» дисперсии к «малой»,
- ▶ сложности с большим горизонтом прогнозирования.

# ARCH

- ▶ Одна из простых стратегий — смоделировать меняющуюся дисперсию как процесс  $AR(q)$ , используя квадраты оцененных остатков.
- ▶  $ARCH(p)$ :  $\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \alpha_2 u_{t-2}^2 + \dots + \alpha_p u_{t-p}^2$ ,  
где  $\omega > 0$ ,  $\alpha_i \geq 0 \ \forall i = \overline{1, p}$ .
- ▶ В отличие от скользящего среднего, здесь веса не обязательно равны  $1/N$ .
- ▶ Прогнозы:  
$$E[u_{t+1}^2] = \sigma_{t+1}^2 = \alpha_0 + \alpha_1 u_t^2 + \alpha_2 u_{t-1}^2 + \dots + \alpha_p u_{t+1-p}^2.$$

# Примеры ARCH

$$a) \quad z_t = WN(0, 1), \quad b) \quad u_t = z_t \sqrt{1 + 0.8u_{t-1}^2}$$



$$c) \quad x_t = 0.2x_{t-1} + u_t,$$

$$d) \quad x_t = 0.9x_{t-1} + u_t$$

# GARCH

ARCH-модель предполагает зависимость дисперсии только от квадратов прошлых значений временного ряда.

Обобщить данную модель можно, предположив, что дисперсия зависит также от прошлых значений самой дисперсии (аналог ARMA).

**GARCH**( $p, q$ ):

$$\sigma_t^2 = \omega + \sum_{i=1}^p \alpha_i u_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2$$

Здесь  $\omega > 0$ ,  $\alpha_i \geq 0 \forall i = \overline{1, p}$ ,  $\beta_j \geq 0 \forall j = \overline{1, q}$ .

## Основное преимущество:

- ▶ Процесс ARCH(p) требует большого количества лагов для определения структуры зависимости, обычно встречающейся в «сложных» временных рядах.
- ▶ Для этого необходимо оценивать множество параметров.
- ▶ Модель GARCH допускает более гибкую и экономную спецификацию.



## Некоторые важные недостатки:

- ▶ В моделях GARCH положительные и отрицательные возмущения одинаково влияют на дисперсии. Однако на практике такое изменение влияет на динамику временного ряда по-разному.
- ▶ В предыдущих моделях автокорреляционная функция экспоненциально убывает, но прикладные задачи показывают, что квадратичное затухание встречается чаще: такое высокое постоянство может быть достигнуто только с помощью сильно параметризованных GARCH моделей.

## Краткое повторение. Модель SARIMAX

К модели SARIMA(p,d,q)(P,D,Q) добавляются *экзогенные* переменные, значение которых формируется вне модели. Экзогенные переменные являются в модели независимыми величинами.

$$x_t = \mu + \sum_{j=1}^p \phi_j x_{t-j} + u_t + \sum_{s=1}^q \theta_s u_{t-s} + \dots + \sum_{i=1}^r \beta_i x_i^{\text{exog}}$$

# Модель векторной авторегрессии

- ▶ Динамика сложных явлений описывается несколькими временными рядами.
- ▶ Временные ряды изменяются синхронно в определенной взаимозависимости.
- ▶ Необходимы методы совместного моделирования двух или более временных рядов.

# Vector Autoregression (VAR)

Рассмотрим подходы к методам совместного моделирования двух или более временных рядов.

Модель векторной авторегрессии VAR( $p$ ) порядка  $p$ :

$$x_t = \mu_1 + \sum_{j=1}^p \beta_j x_{t-j} + \sum_{j=1}^p \gamma_j y_{t-j} + u_t$$

$$y_t = \mu_2 + \sum_{j=1}^p \delta_j x_{t-j} + \sum_{j=1}^p \theta_j y_{t-j} + v_t$$

Здесь  $\beta, \gamma, \delta, \theta$  и  $\mu$  - настраиваемые параметры модели,  $u_t, v_t \sim WN(0, 1)$ .

**Важно:** в модели VAR все факторы рассматриваются как эндогенные.

## Vector Autoregression (VAR)

В терминах матричных обозначений,

$$\mathbf{x}_t = \boldsymbol{\mu} + \sum_{j=1}^p A_j \mathbf{x}_{t-j} + \mathbf{u}_t,$$


$$\text{где } \mathbf{x}_t = \begin{pmatrix} x_{1,t} \\ \vdots \\ x_{k,t} \end{pmatrix}, \boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_k \end{pmatrix}, \mathbf{u}_t = \begin{pmatrix} u_{1,t} \\ \vdots \\ u_{k,t} \end{pmatrix},$$

$A_j$  – матрицы размера  $k \times k$ .

# Vector Autoregression (VAR). Пример.

$$\text{VAR} : x_t = \mu_1 + Ax_{t-j} + u_t$$

$$A = \begin{pmatrix} 0.7 & 0.2 \\ 0.2 & 0.7 \end{pmatrix}$$



- ▶ При изменяющейся дисперсии ARMA не применима.
- ▶ Динамику изменения дисперсии описывает взвешенная сумма предыстории ошибок или оценок дисперсии.
- ▶ Модель AR, примененная к истории ошибок, приводит к модели ARCH.
- ▶ Модель GARCH — это обобщение модели ARCH, использующее предысторию оценок дисперсии  $\sigma_t^2$ .
- ▶ Созависимые временные ряды включаются в модель не только как экзогенные переменные.
- ▶ Многомерные временные ряды моделируются с помощью векторных моделей.
- ▶ Модель VAR — векторная авторегрессия, моделирующая несколько временных рядов.