

Mathematical Forecasting Methods

Лекция 3

МФТИ

Осень, 2023

Краткое повторение

- ▶ **Временной ряд** — это совокупность значения параметра $\{x_1, x_2, \dots, x_T\} = \{x_t\}_{t=1}^T$, изменяющегося во времени, через равные промежутки времени.
- ▶ **Также рассматриваем как:** совокупность случайных величин (*дискретный случайный или стохастический процесс*), где для каждого t значение рассматривается как случайная величина.
- ▶ **Задача прогнозирования:** найти функции $f_{T,d}$:


$$x_{T+d} \approx f_{T,d}(x_1, \dots, x_T; w) =: \hat{x}_{T+d},$$

где $f_{T,d}$ — модель временного ряда, $d = 1, \dots, D$ — горизонт прогнозирования.

Краткое повторение

Определение. Временной ряд $\{x_i\}_{i=1}^T$ называется слабо стационарным (или стационарным в широком смысле), если

- ▶ $E[x_t] = \text{const}$ (т.е. временной ряд не имеет *тренда*),
- ▶ $\text{Cov}(x_t, x_{t+k}) = E[(x_t - Ex_t)(x_{t+k} - Ex_{t+k})] = \gamma(k)$ (ковариация зависит только от разницы во времени).



Белый шум


Краткое повторение

Модель **SARIMAX**($p, q, d; P, Q, D$) приводит временной ряд к стационарному виду и прогнозирует с наперед заданной точностью (по Теореме Вольда).

$$\begin{aligned} x_t = & \underbrace{\mu + \phi_1 x_{t-1} + \phi_2 x_{t-2} + \dots}_{p \text{ слагаемых AR}} + \underbrace{u_t + \theta_1 u_{t-1} + \theta_2 u_{t-2} + \dots}_{q \text{ слагаемых MA}} \\ & + \underbrace{\alpha_1 x_{t-S} + \alpha_2 x_{t-2S} + \dots}_{P \text{ сезонных слагаемых AR}} + \underbrace{\eta_1 u_{t-S} + \eta_2 u_{t-2S} + \dots}_{Q \text{ сезонных слагаемых MA}} \\ & + \underbrace{\beta_1 z_1 + \beta_2 z_2 + \beta_3 z_3 + \dots}_{\text{внешние переменные, не зависящие от } x_t}, \end{aligned}$$

где $\phi, \theta, \alpha, \eta, \beta$ — настраиваемые параметры модели,
 x_t — значения временного ряда (продифференцированные d и D сезонных раз),
 u_t — значения шумов,
 z_i — внешние (экзогенные) переменные.

Проблема непостоянной дисперсии



Дневные изменения фондового индекса биржи

ARCH и GARCH модели

В традиционных эконометрических моделях дисперсия шума считается постоянной (гомоскедастичность).

Если временные ряды демонстрируют периоды необычно большой волатильности, за которыми следуют периоды относительного спокойствия, предположение о постоянной дисперсии не выполняется

- ▶ ARCH (autoregressive conditional heteroskedastic model),
- ▶ GARCH (generalized autoregressive conditional heteroskedastic model).

Изменяющаяся волатильность

- ▶ **Волатильность** в финансовой аналитике — это отклонение доходности (непредсказуемая часть цен на активы).
- ▶ Непредсказуемая часть — это случайная часть или ошибка в предсказании.
- ▶ Модель AR(1): $x_t = \mu + \phi_1 x_{t-1} + u_t = \mu_t + u_t$
- ▶ где μ_t и u_t — ожидаемая часть с учетом истории и случайная часть соответственно.
- ▶ Если ранее полагалось, что $u_t \sim WN(0, 1)$, то теперь возмущения будут моделироваться с меняющейся во времени дисперсией σ_t^2 :

$$u_t = z_t \sqrt{\sigma_t^2},$$

где $z_t \sim WN(0, 1)$,

$$\sigma_t^2 = E(u_t^2 | \text{прошлое}) = E[(x_t - \mu_t)^2 | \text{прошлое}].$$

Историческая волатильность

Скользящее среднее.



$$\sigma_t^2 = \sum_{i=1}^N \frac{r_{t-i}^2}{N},$$

где r_t — ошибка прошлых прогнозов,

- ▶ учитывает изменения с задержкой,
- ▶ сложности с большим горизонтом прогнозирования.

Экспоненциальное сглаживание



$$\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) \sigma_{t-2}^2,$$





- ▶ новый гиперпараметр λ ,
- ▶ нестабильный переход от "большой" дисперсии к "малой",
- ▶ сложности с большим горизонтом прогнозирования.

ARCH

- ▶ Одна из простых стратегий — смоделировать условную дисперсию как процесс $AR(q)$, используя квадраты оцененных остатков.
- ▶ $ARCH(p)$: $\sigma_t^2 = \alpha_0 + \alpha_1 u_{t-1}^2 + \alpha_2 u_{t-2}^2 + \dots + \alpha_p u_{t-p}^2$,
где $\omega > 0$, $\alpha_i \geq 0 \ \forall i = \overline{1, p}$.
- ▶ В отличие от скользящего среднего, здесь веса не обязательно равны $1/N$.
- ▶ Прогнозы:
$$E[u_{t+1}^2] = \sigma_{t+1}^2 = \alpha_0 + \alpha_1 u_t^2 + \alpha_2 u_{t-1}^2 + \dots + \alpha_p u_{t+1-p}^2.$$

Примеры ARCH

$$a) \quad z_t = WN(0, 1), \quad b) \quad u_t = z_t \sqrt{1 + 0.8u_{t-1}^2}$$



$$c) \quad x_t = 0.2x_{t-1} + u_t,$$

$$d) \quad x_t = 0.9x_{t-1} + u_t$$

GARCH

ARCH-модель предполагает зависимость дисперсии только от квадратов прошлых значений временного ряда.

Обобщить данную модель можно, предположив, что дисперсия зависит также от прошлых значений самой дисперсии (аналог ARMA).

GARCH(p, q):

$$\sigma_t^2 = \omega + \sum_{i=1}^p \alpha_i u_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2$$

Здесь $\omega > 0$, $\alpha_i \geq 0 \forall i = \overline{1, p}$, $\beta_j \geq 0 \forall j = \overline{1, q}$.

Основное преимущество:

- ▶ Процесс ARCH(p) требует большого количества лагов для определения структуры зависимости, обычно встречающейся в "сложных" временных рядах.
- ▶ Для этого необходимо оценивать множество параметров.
- ▶ Модель GARCH допускает более гибкую, но экономную спецификацию.

Некоторые важные недостатки:

- ▶ В моделях GARCH положительные и отрицательные возмущения одинаково влияют на дисперсии. Однако на практике такое изменение влияет на динамику временного ряда по-разному.
- ▶ В предыдущих моделях автокорреляционная функция экспоненциально убывает, но прикладные задачи показывают, что квадратичное затухание встречается чаще: такое высокое постоянство может быть достигнуто только с помощью сильно параметризованных GARCH моделей.

Краткое повторение. Модель SARIMAX

К модели SARIMA(p,d,q)(P,D,Q) добавляются *экзогенные* переменные, значение которых формируется вне модели. Экзогенные переменные являются в модели независимыми величинами, а их изменение называется автономным изменением.

$$x_t = \mu + \sum_{j=1}^p \phi_j x_{t-j} + u_t + \sum_{s=1}^q \theta_s u_{t-s} + \dots + \underbrace{\sum_{i=1}^r \beta_i x_i^{\text{exog}}}$$

Модель векторной авторегрессии

- ▶ Динамика сложных явлений описывается несколькими временными рядами.
- ▶ Временные ряды изменяются синхронно в определенной взаимозависимости.
- ▶ Необходимы методы совместного моделирования двух или более временных рядов.

Vector Autoregression (VAR)

Рассмотрим подходы к методам совместного моделирования двух или более временных рядов.

Модель векторной авторегрессии VAR(p) порядка p :

$$x_t = \mu_1 + \sum_{j=1}^p \beta_j x_{t-j} + \sum_{j=1}^p \gamma_j y_{t-j} + u_t$$

$$y_t = \mu_2 + \sum_{j=1}^p \delta_j x_{t-j} + \sum_{j=1}^p \theta_j y_{t-j} + v_t$$

Здесь $\beta, \gamma, \delta, \theta$ и μ - настраиваемые параметры модели, $u_t, v_t \sim WN(0, 1)$.

Важно: в модели VAR все факторы рассматриваются как эндогенные.

Vector Autoregression (VAR)

В терминах матричных обозначений,

$$\mathbf{x}_t = \boldsymbol{\mu} + \sum_{j=1}^p A_j \mathbf{x}_{t-j} + \mathbf{u}_t,$$

где $\mathbf{x}_t = \begin{pmatrix} x_{1,t} \\ \vdots \\ x_{k,t} \end{pmatrix}$, $\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \vdots \\ \mu_k \end{pmatrix}$, $\mathbf{u}_t = \begin{pmatrix} u_{1,t} \\ \vdots \\ u_{k,t} \end{pmatrix}$,

A_j – матрицы размера $k \times k$.

Vector Autoregression (VAR). Пример.

$$\text{VAR} : x_t = \mu_1 + Ax_{t-j} + u_t$$


$$A = \begin{pmatrix} 0.7 & 0.2 \\ 0.2 & 0.7 \end{pmatrix}$$



Важно: коэффициенты VAR-модели в общем случае не интерпретируемы.

Резюме

- ▶ При изменяющейся дисперсии ARMA не применима.
- ▶ Динамику изменения дисперсии описывает взвешенная сумма предыстории ошибок или оценок дисперсии.
- ▶ Модель ARMA, примененная к истории ошибок, приводит к модели ARCH.
- ▶ Модель GARCH — это обобщение модели ARCH, использующее предысторию оценок дисперсии σ_t^2 .
- ▶ Созависимые временные ряды включаются в модель не только как экзогенные переменные.
- ▶ Многомерные временные ряды моделируются с помощью векторных моделей.
- ▶ Модель VAR — векторная авторегрессия, моделирующая несколько временных рядов.



Дневные изменения фондового индекса биржи