

Mathematical Forecasting Methods

Лекция 12

МФТИ

Весна, 2024

Напоминание

- ▶ Два способа представить каноническое разложение:

$$\underline{\mathbf{X}} = \sum_{r=1}^R \mathbf{b}_r^{(1)} \circ \mathbf{b}_r^{(2)} \circ \dots \circ \mathbf{b}_r^{(N)} = \llbracket \mathbf{I}; \mathbf{B}^{(1)}, \mathbf{B}^{(2)}, \dots, \mathbf{B}^{(N)} \rrbracket$$

- ▶ Алгоритм ALS позволяет приближенно находить каноническое разложение тензора.
- ▶ Норма Фробениуса

$$\|\underline{\mathbf{A}}\|_F = \sqrt{\sum_{i_1, \dots, i_N} a_{i_1, \dots, i_N}^2} = \|\text{vec}(\underline{\mathbf{A}})\|_2$$

- ▶ (дополнение) Норма Фробениуса для тензоров порождается скалярным произведением (тензоры $\underline{\mathbf{A}}$ и $\underline{\mathbf{B}}$ имеют одинаковый порядок и их размерности совпадают):

$$\langle \underline{\mathbf{A}}, \underline{\mathbf{B}} \rangle = \sqrt{\sum_{i_1, \dots, i_N} a_{i_1, \dots, i_N} b_{i_1, \dots, i_N}}$$

Разложение Такера

$\underline{\mathbf{X}} \in \mathbb{R}^{I_1 \times I_2 \times \dots \times I_N}$ - тензор N -ого порядка.

- ▶ Каноническое разложение может быть представлено в виде произведения Такера с единичным тензором $\underline{\mathbf{I}}$ (или диагональным тензором $\underline{\mathbf{\Lambda}}$) и набором фактор-матриц $\mathbf{B}^{(1)}, \dots, \mathbf{B}^{(N)}$:

$$\underline{\mathbf{X}} = [\underline{\mathbf{I}}; \mathbf{B}^{(1)}, \dots, \mathbf{B}^{(N)}] \quad \text{или} \quad \underline{\mathbf{X}} = [\underline{\mathbf{\Lambda}}; \mathbf{B}^{(1)}, \dots, \mathbf{B}^{(N)}]$$

- ▶ Каноническое разложение - частный случай *Разложения Такера*. Разложение Такера представляется в виде произведения Такера **произвольного** тензора $\underline{\mathbf{G}} \in \mathbb{R}^{R_1 \times \dots \times R_N}$ (core tensor, *центральный* тензор) и фактор-матриц $\mathbf{U}^{(n)}$:

$$\underline{\mathbf{X}} = [\underline{\mathbf{G}}; \mathbf{U}^{(1)}, \dots, \mathbf{U}^{(N)}] := \underline{\mathbf{G}} \times_1 \mathbf{U}^{(1)} \times_2 \mathbf{U}^{(2)} \times_3 \dots \times_N \mathbf{U}^{(N)}$$

- ▶ Мультилинейный ранг тензора - вектор рангов его развёрток:

$$\text{rank}_{\text{ML}}(\underline{\mathbf{X}}) = \left(\text{rank}(\mathbf{X}_{(1)}), \dots, \text{rank}(\mathbf{X}_{(N)}) \right)$$

Сингулярное Разложение (Singular Value Decomp., SVD)


Для аналогии вспомним разложение в случае матриц.

Любая матрица $\mathbf{X} \in \mathbb{R}^{m \times n}$ представима в виде

$$\mathbf{X} = \mathbf{U}\Sigma\mathbf{V}^T = \Sigma \times_1 \mathbf{U} \times_2 \mathbf{V} = \llbracket \Sigma; \mathbf{U}, \mathbf{V} \rrbracket$$

Здесь:

- ▶ Матрицы $\mathbf{U} \in \mathbb{R}^{m \times m}$, $\mathbf{V} \in \mathbb{R}^{n \times n}$ - ортогональные матрицы
- ▶ $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_{\min(m,n)}) \in \mathbb{R}^{m \times n}$ — диагональная матрица сингулярных чисел, где $\sigma_1 \geq \dots \geq \sigma_{\min(m,n)} \geq 0$



Higher-order singular values decomposition

В случае тензоров можно применить ту же логику, как и в матричном SVD.

Любой тензор $\underline{\mathbf{X}} \in \mathbb{R}^{I_1 \times \dots \times I_N}$ представляется в виде

$$\underline{\mathbf{X}} = [\![\underline{\mathbf{S}}; \mathbf{U}^{(1)}, \dots, \mathbf{U}^{(d)}]\!]$$

При этом:

- ▶ $\mathbf{U}^{(k)} \in \mathbb{R}^{n_k \times n_k}$ - ортогональные матрицы (factor matrices), условие аналогичное матричному SVD.
- ▶ В тензоре $\underline{\mathbf{S}}$ подтензоры $\underline{\mathbf{S}}_{:, \dots, :, i_n, :, \dots, :}$ имеют свойства:
 - ▶ $\langle \underline{\mathbf{S}}_{:, \dots, :, i_n, :, \dots, :}, \underline{\mathbf{S}}_{:, \dots, :, j_n, :, \dots, :} \rangle_F = 0$ для $i_n \neq j_n$, где $i_n, j_n \in \overline{1, I_n}$, то есть подтензоры, соответствующие разным индексам вдоль одной моды, взаимно ортогональны,
 - ▶ $\|\underline{\mathbf{S}}_{:, \dots, :, i_n, :, \dots, :}\|_F \geq \|\underline{\mathbf{S}}_{:, \dots, :, j_n, :, \dots, :}\|_F$ при $i_n \geq j_n$, где норма $\sigma_{i_n} := \|\underline{\mathbf{S}}_{:, \dots, :, i_n, :, \dots, :}\|_F$ - это сингулярное число развёртки вдоль соответствующей моды $\underline{\mathbf{S}}_{(n)}$.

Алгоритм Sequentially Truncated Higher Order SVD

Input: тензор $\underline{\mathbf{X}} \in \mathbb{R}^{I_1 \times \dots \times I_N}$ N -ого порядка и точность аппроксимации ε .

Output: HOSVD-разложение тензора $\hat{\underline{\mathbf{X}}} = [\underline{\mathbf{S}}; \mathbf{U}^{(1)}, \dots, \mathbf{U}^{(N)}]$, при этом $\|\underline{\mathbf{X}} - \hat{\underline{\mathbf{X}}}\|_F \leq \varepsilon$.

1. **for** $n = 1, \dots, N$ **do**:
2. $\mathbf{U}^{(n)}, \mathbf{S}^{(n)}, \mathbf{V}^{(n)} = \text{truncated_SVD}(\mathbf{X}_{(n)}, \frac{\varepsilon}{\sqrt{N}})$
 $\mathbf{U}^{(n)} \in \mathbb{R}^{I_n \times R_n}, \mathbf{S}^{(n)} \in \mathbb{R}^{R_n \times R_n}, \mathbf{V}^{(n)} \in \mathbb{R}^{R_n \times I_1 \dots I_{n-1} I_{n+1} \dots I_N}$
3. **end for**
4. $\underline{\mathbf{S}} = [\underline{\mathbf{X}}; \mathbf{U}^{(1)\top}, \dots, \mathbf{U}^{(N)\top}]$
5. **return** тензор $\underline{\mathbf{S}}$ и фактор-матрицы $\mathbf{U}^{(n)} \in \mathbb{R}^{I_n \times R_n}$

- ▶ Алгоритм не даёт наилучшего приближения в семействе тензоров соответствующего мультилинейного ранга (в отличие от SVD в случае матриц).
- ▶ Однако, для результирующего тензора $\hat{\underline{\mathbf{X}}}$ гарантируется свойство квазиоптимальности.

Проблема Sequentially Truncated Higher Order SVD

- ▶ В отличие от стандартного SVD для матриц, Truncated Higher Order SVD не дает наилучшего мультилинейного рангового приближения, но удовлетворяет свойству квазинаилучшего приближения

$$\|\underline{\mathbf{X}} - \llbracket \underline{\mathbf{S}}; \mathbf{U}^{(1)}, \dots, \mathbf{U}^{(N)} \rrbracket\| \leq \sqrt{N} \|\underline{\mathbf{X}} - \underline{\mathbf{X}}_{\text{Best}}\|$$

,

где $\underline{\mathbf{X}}_{\text{Best}}$ — это наилучшее приближение заданного мультилинейного ранга тензора $\underline{\mathbf{X}}$ для нормы $\|\cdot\|$.

- ▶ Для поиска наилучшего приближения применяется аналог алгоритма ALS, называемый Higher Order Orthogonal Iteration (HOOI), который позволяет улучшить оценку фактор-матриц и центрального тензора в HOSVD.

Алгоритм Higher Order Orthogonal Iteration

Input: тензор $\underline{\mathbf{X}} \in \mathbb{R}^{I_1 \times \dots \times I_N}$ N -ого порядка.

Output: Наилучшее приближение исходного тензора в виде разложения Такера с ортогональными фактор-матрицами $\mathbf{U}^{(n)}$.

1. Инициализируем разложение Такера
 $\underline{\mathbf{X}} = \llbracket \underline{\mathbf{S}}; \mathbf{U}^{(1)}, \dots, \mathbf{U}^{(N)} \rrbracket$ с помощью HOSVD.
2. **repeat**
3. **for** $n = 1, \dots, N$ **do**:
4. $\underline{\mathbf{Z}} = \llbracket \underline{\mathbf{X}}; \mathbf{U}^{(1)\top}, \dots, \mathbf{U}^{(n-1)\top}, \mathbf{I}, \mathbf{U}^{(n+1)\top}, \dots, \mathbf{U}^{(N)\top} \rrbracket$
5. $\mathbf{C} = \mathbf{Z}_{(n)} \mathbf{Z}_{(n)}^\top \in \mathbb{R}^{I_n \times I_n}$
6. $\mathbf{U}_{(n)}$ – матрица из R_n старших собств. векторов \mathbf{C}
7. **end for**
8. $\underline{\mathbf{G}} = \llbracket \underline{\mathbf{X}}; \mathbf{U}^{(1)\top}, \dots, \mathbf{U}^{(N)\top} \rrbracket = \underline{\mathbf{Z}} \times_N \mathbf{U}^{(N)}$
9. **until** разность норм $\|\underline{\mathbf{X}}\|_F - \|\underline{\mathbf{G}}\|_F$ не перестанет убывать
10. **return** тензор $\underline{\mathbf{G}}$ и фактор-матрицы $\mathbf{U}^{(n)} \in \mathbb{R}^{I_n \times R_n}$

Разложение Такера

CP Decomposition	Tucker Decomposition
Scalar representation	
$x_{ijk} = \sum_{r=1}^R \lambda_r a_{ir} b_{jr} c_{kr}$	$x_{ijk} = \sum_{r_1=1}^{R_1} \sum_{r_2=1}^{R_2} \sum_{r_3=1}^{R_3} g_{r_1 r_2 r_3} a_{ir_1} b_{jr_2} c_{kr_3}$
Tensor representation, outer products	
$\underline{\mathbf{X}} = \sum_{r=1}^R \lambda_r \mathbf{a}_r \circ \mathbf{b}_r \circ \mathbf{c}_r$	$\underline{\mathbf{X}} = \sum_{r_1=1}^{R_1} \sum_{r_2=1}^{R_2} \sum_{r_3=1}^{R_3} g_{r_1 r_2 r_3} \mathbf{a}_{r_1} \circ \mathbf{b}_{r_2} \circ \mathbf{c}_{r_3}$
Tensor representation, multilinear products	
$\begin{aligned} \underline{\mathbf{X}} &= \underline{\mathbf{A}} \times_1 \mathbf{A} \times_2 \mathbf{B} \times_3 \mathbf{C} \\ &= [\underline{\mathbf{A}}; \mathbf{A}, \mathbf{B}, \mathbf{C}] \end{aligned}$	$\begin{aligned} \underline{\mathbf{X}} &= \underline{\mathbf{G}} \times_1 \mathbf{A} \times_2 \mathbf{B} \times_3 \mathbf{C} \\ &= [\underline{\mathbf{G}}; \mathbf{A}, \mathbf{B}, \mathbf{C}] \end{aligned}$
Matrix representations	
$\begin{aligned} \mathbf{X}_{(1)} &= \mathbf{A} \underline{\mathbf{A}} (\mathbf{B} \odot_L \mathbf{C})^T \\ \mathbf{X}_{(2)} &= \mathbf{B} \underline{\mathbf{A}} (\mathbf{A} \odot_L \mathbf{C})^T \\ \mathbf{X}_{(3)} &= \mathbf{C} \underline{\mathbf{A}} (\mathbf{A} \odot_L \mathbf{B})^T \end{aligned}$	$\begin{aligned} \mathbf{X}_{(1)} &= \mathbf{A} \mathbf{G}_{(1)} (\mathbf{B} \otimes_L \mathbf{C})^T \\ \mathbf{X}_{(2)} &= \mathbf{B} \mathbf{G}_{(2)} (\mathbf{A} \otimes_L \mathbf{C})^T \\ \mathbf{X}_{(3)} &= \mathbf{C} \mathbf{G}_{(3)} (\mathbf{A} \otimes_L \mathbf{B})^T \end{aligned}$
Vector representation	
$\text{vec}(\underline{\mathbf{X}}) = (\mathbf{A} \odot_L \mathbf{B} \odot_L \mathbf{C}) \underline{\lambda}$	$\text{vec}(\underline{\mathbf{X}}) = (\mathbf{A} \otimes_L \mathbf{B} \otimes_L \mathbf{C}) \text{vec}(\underline{\mathbf{G}})$
Matrix slices $\mathbf{X}_k = \mathbf{X}(:, :, k)$	
$\mathbf{X}_k = \mathbf{A} \text{diag}(\lambda_1 c_{k,1}, \dots, \lambda_R c_{k,R}) \mathbf{B}^T$	$\mathbf{X}_k = \mathbf{A} \left(\sum_{r_3=1}^{R_3} c_{kr_3} \mathbf{G}(:, :, r_3) \right) \mathbf{B}^T$

- ▶ Каноническое разложение в виде произведения Такера - частный случай разложения Такера.
- ▶ Используя разложение Такера, можно обобщить матричный SVD на тензорный случай HOSVD.
- ▶ HOSVD в чистом виде позволяет построить квазиоптимальное приближение исходного тензора, используя в своей основе матричный SVD.
- ▶ Один из алгоритмов позволяющих уточнить приближение тензора, HOOI, позволяет итеративно находить матрицы факторов с помощью рассмотрения развёрток тензоров.