

Mathematical Forecasting Methods

Лекция 13

МФТИ

Весна, 2024


Краткое повторение: SVD

Для аналогии вспомним разложение в случае матриц.
Любая матрица $\mathbf{X} \in \mathbb{R}^{m \times n}$ представима в виде

$$\mathbf{X} = \mathbf{U}\Sigma\mathbf{V}^T = \Sigma \times_1 \mathbf{U} \times_2 \mathbf{V} = \llbracket \Sigma; \mathbf{U}, \mathbf{V} \rrbracket$$

Здесь:

- ▶ Матрицы $\mathbf{U} \in \mathbb{R}^{m \times m}$, $\mathbf{V} \in \mathbb{R}^{n \times n}$ - ортогональные матрицы
- ▶ $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_{\min(m,n)}) \in \mathbb{R}^{m \times n}$ — диагональная матрица сингулярных чисел, где $\sigma_1 \geq \dots \geq \sigma_{\min(m,n)} \geq 0$



Краткое повторение: HOSVD

В случае тензоров можно применить ту же логику, как и в матричном SVD.

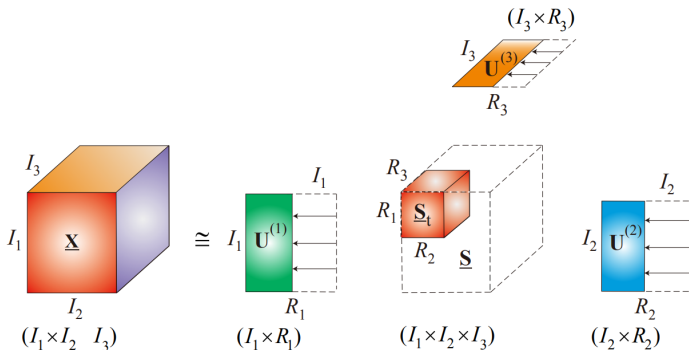
Любой тензор $\underline{\mathbf{X}} \in \mathbb{R}^{I_1 \times \dots \times I_N}$ представляется в виде

$$\underline{\mathbf{X}} = [\underline{\mathbf{S}}; \mathbf{U}^{(1)}, \dots, \mathbf{U}^{(d)}]$$

При этом:

- ▶ $\mathbf{U}^{(k)} \in \mathbb{R}^{n_k \times n_k}$ - ортогональные матрицы (factor matrices), условие аналогичное матричному SVD.
- ▶ В тензоре $\underline{\mathbf{S}}$ подтензоры $\underline{\mathbf{S}}_{:, \dots, :, i_n, :, \dots, :}$ имеют свойства:
 - ▶ $\langle \underline{\mathbf{S}}_{:, \dots, :, i_n, :, \dots, :}, \underline{\mathbf{S}}_{:, \dots, :, j_n, :, \dots, :} \rangle_F = 0$ для $i_n \neq j_n$, где $i_n, j_n \in \overline{1, I_n}$, то есть подтензоры, соответствующие разным индексам вдоль одной моды, взаимно ортогональны,
 - ▶ $\|\underline{\mathbf{S}}_{:, \dots, :, i_n, :, \dots, :}\|_F \geq \|\underline{\mathbf{S}}_{:, \dots, :, j_n, :, \dots, :}\|_F$ при $i_n \geq j_n$, где норма $\sigma_{i_n} := \|\underline{\mathbf{S}}_{:, \dots, :, i_n, :, \dots, :}\|_F$ - это сингулярное число развёртки вдоль соответствующей моды $\underline{\mathbf{S}}_{(n)}$.

Краткое повторение: HOSVD



Partial least squares regression

Метод PLS позволяет выделить из исходных данных компоненты, между которыми существует ковариационная связь.

- ▶ Принцип метода PLS заключается в поиске общего набора скрытых переменных в независимой переменной $\mathbf{X} \in \mathbb{R}^{I \times J}$ и зависимой переменной $\mathbf{Y} \in \mathbb{R}^{I \times M}$ с помощью разложения.
- ▶ Компоненты, полученные в результате такого разложения, учитывают ковариацию между \mathbf{X} и \mathbf{Y} .

Partial least squares regression

Задача заключается в том, чтобы представить матрицы \mathbf{X} и \mathbf{Y} в следующем виде:

$$\mathbf{X} = \mathbf{T}\mathbf{P}^T + \mathbf{E} = \sum_{r=1}^R \mathbf{t}_r \mathbf{p}_r^T + \mathbf{E},$$

$$\mathbf{Y} = \mathbf{T}\mathbf{D}\mathbf{C}^T + \mathbf{F} = \sum_{r=1}^R d_{rr} \mathbf{t}_r \mathbf{c}_r^T + \mathbf{F},$$

где

- ▶ $\mathbf{T} \in \mathbb{R}^{I \times R}$ матрица скрытых переменных из \mathbf{X} ,
- ▶ $\mathbf{U} = \mathbf{T}\mathbf{D}$ матрица скрытых переменных из \mathbf{Y} , имеющих наибольшую ковариацию с \mathbf{T} ,
- ▶ \mathbf{D} — диагональная масштабирующая матрица (линейное отображение),
- ▶ \mathbf{P} и \mathbf{C} — матрицы весов,
- ▶ \mathbf{E} и \mathbf{F} — регрессионные остатки

Partial least squares regression

Стандартный алгоритм PLS:

- ▶ находит два набора весовых векторов \mathbf{w} и \mathbf{c} с помощью следующей задачи оптимизации:

$$\begin{aligned} \max_{\{\mathbf{w}, \mathbf{c}\}} \quad & (\mathbf{w}^T \mathbf{X}^T \mathbf{Y} \mathbf{c})^2, \\ \text{s.t.} \quad & \mathbf{w}^T \mathbf{w} = 1, \quad \mathbf{c}^T \mathbf{c} = 1, \end{aligned}$$

- ▶ искомые скрытые выражаются как $\mathbf{t} = \frac{\mathbf{X} \mathbf{w}}{\|\mathbf{X} \mathbf{w}\|_2}$ и $\mathbf{u} = \mathbf{Y} \mathbf{c}$,
- ▶ итерация повторяется пока не будет набрано желаемое число компонент.

Partial least squares regression

$$\begin{aligned}
 \mathbf{X} &= \mathbf{T} \mathbf{P}^T + \mathbf{E} = \sum_{r=1}^R \begin{bmatrix} \mathbf{p}_r \\ \mathbf{t}_r \end{bmatrix} + \mathbf{E} \\
 \mathbf{Y} &= \mathbf{T} \mathbf{D} \mathbf{C}^T + \mathbf{F} = \sum_{r=1}^R \begin{bmatrix} d_{rr} \mathbf{c}_r \\ \mathbf{t}_r \end{bmatrix} + \mathbf{F}
 \end{aligned}$$

\mathbf{X} ($I \times J$) \mathbf{T} ($I \times R$) \mathbf{P}^T ($R \times J$) \mathbf{E} ($I \times J$)

\mathbf{Y} ($I \times M$) \mathbf{T} ($I \times R$) \mathbf{D} ($R \times R$) \mathbf{C}^T ($R \times M$) \mathbf{F} ($I \times M$)

Higher-Order Partial Least Squares

В случае тензоров, используя обобщенный HOSVD, можно применить ту же логику для PLS.

- ▶ Обобщенная модель регрессии HOPLS выполняет одновременное разложение Такера с ограничениями для тензора с одинаковой размерностью первой моды, т.е. числа объектов в выборке.
- ▶ Предполагается, что $\underline{\mathbf{X}}$ разлагается как сумма блоков Такера ранга $(1, L_1, \dots, L_N)$, а $\underline{\mathbf{Y}}$ разлагается как сумма блоков Такера ранга $(1, K_1, \dots, K_N)$, которые можно выразить как

$$\underline{\mathbf{X}} = \sum_{r=1}^R \mathbf{G}_{xr} \times_1 \mathbf{t}_r \times_2 \mathbf{P}_r^{(1)} \dots \times_{N+1} \mathbf{P}_r^{(N)} + \underline{\mathbf{E}}_R$$
$$\underline{\mathbf{Y}} = \sum_{r=1}^R \mathbf{G}_{yr} \times_1 \mathbf{t}_r \times_2 \mathbf{Q}_r^{(1)} \dots \times_{N+1} \mathbf{Q}_r^{(N)} + \underline{\mathbf{F}}_R.$$

Higher-Order Partial Least Squares

Модель HOPLS представима в виде:

$$\begin{aligned}\underline{\mathbf{X}} &= \sum_{r=1}^R \mathbf{G}_{xr} \times_1 \mathbf{t}_r \times_2 \mathbf{P}_r^{(1)} \dots \times_{N+1} \mathbf{P}_r^{(N)} + \underline{\mathbf{E}}_R \\ \underline{\mathbf{Y}} &= \sum_{r=1}^R \mathbf{G}_{yr} \times_1 \mathbf{t}_r \times_2 \mathbf{Q}_r^{(1)} \dots \times_{N+1} \mathbf{Q}_r^{(N)} + \underline{\mathbf{F}}_R.\end{aligned}$$

где

- ▶ $\mathbf{t}_r \in \mathbb{R}^M$ — векторы скрытых переменных по первой моде,
- ▶ $\{\mathbf{P}_r^{(n)}\}_{n=1}^N \in \mathbb{R}^{I_n \times L_n}$ и $\{\mathbf{Q}_r^{(n)}\}_{n=1}^N \in \mathbb{R}^{J_n \times K_n}$ — фактор-матрицы по каждой моде,
- ▶ $\mathbf{G}_{xr} \in \mathbb{R}^{1 \times L_1 \times \dots \times L_n}$ и $\mathbf{G}_{yr} \in \mathbb{R}^{1 \times K_1 \times \dots \times K_n}$ — центральные тензоры разложения

Higher-Order Partial Least Squares

$$\begin{array}{c} \text{X} \\ (M \times I_1 \times I_2) \end{array} = \begin{array}{c} \mathbf{P}_1^{(2)} \quad (I_2 \times L_2) \\ \mathbf{P}_1^{(1)T} \quad (L_1 \times I_1) \\ (1 \times L_1 \times L_2) \end{array} \mathbf{t}_1^{(M \times 1)} + \dots + \begin{array}{c} \mathbf{P}_R^{(2)} \quad (I_2 \times L_2) \\ \mathbf{P}_R^{(1)T} \quad (L_1 \times I_1) \\ (1 \times L_1 \times L_2) \end{array} \mathbf{t}_R^{(M \times 1)} + \begin{array}{c} \text{E} \\ (M \times I_1 \times I_2) \end{array}$$

$$= \begin{array}{c} \mathbf{G}_X \\ (M \times R) \end{array} \begin{array}{c} \mathbf{P}^{(2)} \quad (I_2 \times RL_2) \\ \mathbf{P}^{(1)T} \quad (RL_1 \times I_1) \\ (R \times RL_1 \times RL_2) \end{array} + \begin{array}{c} \text{E} \\ (M \times I_1 \times I_2) \end{array}$$

$$\begin{array}{c} \text{Y} \\ (M \times J_1 \times J_2) \end{array} = \begin{array}{c} \mathbf{Q}_1^{(2)} \quad (J_2 \times K_2) \\ \mathbf{Q}_1^{(1)T} \quad (K_1 \times J_1) \\ (1 \times K_1 \times K_2) \end{array} \mathbf{t}_1^{(M \times 1)} + \dots + \begin{array}{c} \mathbf{Q}_R^{(2)} \quad (J_2 \times K_2) \\ \mathbf{Q}_R^{(1)T} \quad (K_1 \times J_1) \\ (1 \times K_1 \times K_2) \end{array} \mathbf{t}_R^{(M \times 1)} + \begin{array}{c} \text{F} \\ (M \times J_1 \times J_2) \end{array}$$

$$= \begin{array}{c} \mathbf{G}_Y \\ (M \times R) \end{array} \begin{array}{c} \mathbf{Q}^{(2)} \quad (J_2 \times RK_2) \\ \mathbf{Q}^{(1)T} \quad (RK_1 \times J_1) \\ (R \times RK_1 \times RK_2) \end{array} + \begin{array}{c} \text{F} \\ (M \times J_1 \times J_2) \end{array}$$

Partial least squares regression

По аналогии со стандартным алгоритмом PLS, в HOPLS:

- ▶ находит два набора фактор-матриц $\mathbf{P}_r^{(n)}$, $\mathbf{Q}_r^{(n)}$ с помощью следующей задачи оптимизации:

$$\begin{aligned} \max_{\{\mathbf{P}^{(n)}, \mathbf{Q}^{(n)}\}} \quad & \llbracket \langle \underline{\mathbf{X}}, \underline{\mathbf{Y}} \rangle_{1;1}; \mathbf{P}^{(1)}, \dots, \mathbf{P}^{(N)}, \mathbf{Q}^{(1)}, \dots, \mathbf{Q}^{(N)} \rrbracket, \\ \text{s.t.} \quad & \mathbf{P}^{(n)\top} \mathbf{P}^{(n)} = \mathbf{I}_{L_n}, \quad \mathbf{Q}^{(n)\top} \mathbf{Q}^{(n)} = \mathbf{I}_{K_n}, \end{aligned}$$

- ▶ Это эквивалентно нахождению наилучшего низкорангового приближения тензора $\langle \underline{\mathbf{X}}, \underline{\mathbf{Y}} \rangle_{1;1}$



Алгоритм Higher Order Partial Least Squares

Input: тензоры $\underline{\mathbf{X}} \in \mathbb{R}^{M \times I_1 \times \dots \times I_N}$ и $\underline{\mathbf{Y}} \in \mathbb{R}^{M \times J_1 \times \dots \times J_N}$.

Output: $\{\mathbf{P}_r^{(n)}\}$, $\{\mathbf{Q}_r^{(n)}\}$, $\{\underline{\mathbf{G}}_{x_r}\}$, $\{\underline{\mathbf{G}}_{y_r}\}$, \mathbf{T} ,
 $n = 1, \dots, N$, $r = 1, \dots, R$.

1. for $r = 1$ to R do
2. $\underline{\mathbf{C}} \leftarrow \langle \underline{\mathbf{X}}, \underline{\mathbf{Y}} \rangle_{1;1} \in \mathbb{R}^{I_1 \times \dots \times I_N \times J_1 \times \dots \times J_N}$.
3. Найдём $\{\mathbf{P}_r^{(n)}\}$ и $\{\mathbf{Q}_r^{(n)}\}$ с помощью HOOI для $\underline{\mathbf{C}}$.
4. $\mathbf{t}_r \leftarrow$ синг. вектор $\left(\underline{\mathbf{X}} \times_2 \mathbf{P}_r^{(1)\top} \times_3 \dots \times_{N+1} \mathbf{P}_r^{(N)\top} \right)_{(1)}$
5. $\underline{\mathbf{G}}_{x_r} \leftarrow \underline{\mathbf{X}} \times_1 \mathbf{t}_r^\top \times_2 \mathbf{P}_r^{(1)\top} \times_3 \dots \times_{N+1} \mathbf{P}_r^{(N)\top}$
6. $\underline{\mathbf{G}}_{y_r} \leftarrow \underline{\mathbf{Y}} \times_1 \mathbf{t}_r^\top \times_2 \mathbf{Q}_r^{(1)\top} \times_3 \dots \times_{N+1} \mathbf{Q}_r^{(N)\top}$
7. $\underline{\mathbf{X}} \leftarrow \underline{\mathbf{X}} - \underline{\mathbf{G}}_{x_r} \times_1 \mathbf{t}_r \times_2 \mathbf{P}_r^{(1)} \times_3 \dots \times_{N+1} \mathbf{P}_r^{(N)}$
8. $\underline{\mathbf{Y}} \leftarrow \underline{\mathbf{Y}} - \underline{\mathbf{G}}_{y_r} \times_1 \mathbf{t}_r \times_2 \mathbf{Q}_r^{(1)} \times_3 \dots \times_{N+1} \mathbf{Q}_r^{(N)}$
9. end for

Пример HOPLS



- ▶ PLS-регрессия — это связанный с SVD статистический метод, который находит модель линейной регрессии, проецируя прогнозируемые переменные и наблюдаемые переменные в новое пространство.
- ▶ В новом пространстве выбираются скрытые переменные с наибольшей ковариацией.
- ▶ По аналогии водится обобщение PLS — HOPLS, основанный на разложении Такера.
- ▶ В этом разложении особую роль играет мода, соответствующая объектам выборки.